Architettura degli Elaboratori

Appunti: Simone Pepi Stesura in LaTEX: Federico Matteoni

Indice

	$0.1 \\ 0.2$		uzione
1			ati di strutturazione
1	1.1		ura a livelli
	1.1		
	1.2		
		1.2.1 $1.2.2$	
			Struttura Interna
		1.2.3	Parallelismo
	1.0	1.2.4	Modelli di Cooperazione
	1.3	Comp	ilazione vs Interpretazione
2	MV		ardware 9
	2.1		ogiche
	2.2	Reti C	Combinatorie
		2.2.1	Algebra Booleana 9
		2.2.2	Tecnica della Somma di Prodotti, o codifica degli 1
		2.2.3	Porte Logiche
		2.2.4	Componenti Standard
		2.2.5	Ritardo di Stabilizzazione
		2.2.6	Registri e memorie
	2.3	Reti S	equenziali
		2.3.1	Modello di Mealy
		2.3.2	Modello di Moore
		2.3.3	Reti Sequenziali di tipo Sincrono
		2.3.4	Reti Sequenziali a Componenti Standard
3	MV	1 - Fi	rmware 17
_	3.1		Firmware
	0.1	3.1.1	PC e PO
		3.1.2	Procedimento Formale
		9	
4		nguage	
	4.1	Istruzi	
	4.2		izzazione del codice
		4.2.1	Condizioni di Bernstein
		4.2.2	Variabili di Condizionamento
		4.2.3	Tempo medio di elaborazione
		4.2.4	Riflessioni finali sull'ottimizzazione
	4.3		ollo Residuo
	4.4	Comu	nicazioni 23
		4.4.1	Protocollo a Livelli
		4.4.2	Protocollo a Transizione di Livello
		4.4.3	Comunicazioni asincrone a n posizioni
		4.4.4	Comunicazioni asimmetriche
	4.5	Momo	nia Madulana

5 Macchina Assembler					
	.1 CPU	30			
	.2 Istruzioni ASM	31			
	.3 Programmi e processi	31			

0.1 Introduzione

Appunti del corso di Architettura degli Elaboratori presi a lezione da Federico Matteoni.

Prof.: **Maurizio Bonuccelli**, maurizio.angelo.bonuccelli@unipi.it Riferimenti web:

- http://pages.di.unipi.it/bonuccelli/aeb.html
- $-\ didawiki.cli.di.unipi.it/doku.php/informatica/ae/start$

Ricevimento: Martedì 10-12, stanza 294 DE

Esame: scritto ($closed\ book$) e orale. I compitini sono validi solo per la sessione invernale (gen-feb) Libri

- M. Vanneschi Architettura degli Elaboratori, Pisa UniversitY Press
- D. A. Patterson Computer Organization & Design The Hardware/Software Interface

0.2 Cosa riguarda il corso

Consiste in come sono fatti pe internamento da un punto di vista di sottosistemi senza scendere nei dettagli elettrici. Il corso è diviso in quattro parti:

- Fondamenti e strutturazione firmware (I Compitino)
- Macchina assembler (D-RISC) e processi
- Architetture General-Purpose
- Architetture parallele (II Compitino)

Capitolo 1

Fondamenti di strutturazione

1.1 Struttura a livelli

Dividere Per dedicarci allo studio di un sistema complesso spesso è utile dividerlo in pezzi. Nel caso di un sistema di elaborazione, in alcuni casi è interessante avere una visione vicina alla struttura fisica in termini di componenti hardware. In altri casi è interessante avere una visione astratta del sistema per poterne osservare le funzionalità e le strutture più adatte alla specifica applicazione.

Astrarre Da questa necessità deriva la possibilità di strutturare un sistema a vari livelli di astrazione che non descrivono una reale struttura fisica, ma è utile per ragioni specifiche quali:

Saper riconoscere quale metodo di progettazione strutturata viene seguito o conviene seguire (top-down, bottom-up, middle-out)

Saper riconoscere se i vari livelli rispettano una relazione gerarchica oppure se non esiste alcun tipo di ordinamento

Essere in grado di valutare a quali livelli conviene descrivere e implementare determinate funzioni del sistema

1.2 Macchine Virtuali

Sistema di elaborazione Le funzionalità di un sistema di elaborazione nel suo complesso possono essere ripartite su un certo numero di livelli che vengono definite macchine virtuali. La suddivisione può seguire due approcci fondamentali:

- Linguistico: stabilisce i livelli in base ai linguaggi usati
- Funzionale: stabilisce i livelli in base a cosa fanno

I vari livelli sono schematizzati come in figura:

Interfaccia					
$MV_i R_i = risorse + L_i = linguaggi$					
Interfaccia					
$MV_{i-1} R_{i-1} = risorse + L_{i-1} = linguaggi$					
Interfaccia					

 MV_i realizza politica P_i con linguaggio L_i e risorse R_i .

 MV_i utilizza le funzionalità che il livello MV_{i-1} (cioè le sue primitive) fornisce **attraverso l'interfaccia**.

L'interfaccia definita è fondamentale per poter rendere possibile la collaborazione tra le macchine virtuali, e permettere così ai linguaggi di MV_i di sfruttare funzionalità e meccanismi di MV_{i-1} .

Le macchine virtuali godono delle **seguenti proprietà**:

L'insieme degli oggetti o risorse \mathbf{R}_i di MV $_i$ è accessibile soltanto da parte dei meccanismi di \mathbf{L}_i

Al livello MV_i non sono note le politiche adottate dai livelli inferiori

Supporto a tempo di esecuzione Anche detto Runtime Support, è l'insieme dei livelli sottostanti. Nell'esempio, MV_i ha come runtime support i livelli $MV_{i-1} \dots MV_0$.

Virtualizzazione ed Emulazione Con virtualizzazione o astrazione intendiamo il processo secondo cui un livello MV_i usa funzionalità dei livelli superiori.

Con emulazione o concretizzazione intendiamo il processo secondo cui un livello MV_i usa funzionalità dei livelli inferiori.

Modularità Tutte queste funzionalità sono alla base della strutturazione di sistemi con elevata modularià, modificabilità, portabilità, manutebilità e testabilità.

Le Macchine Virtuali

\mathbf{MV}_4 Applicazioni
L ₄ : Java, C, ML
R ₄ : oggetti astratti, costrutti, tipi di dato definibili dall'utente
Interfaccia: chiamate di sistema
\mathbf{MV}_3 Sistema Operativo
L ₃ : C, linguaggi di programmazione concorrente, linguaggi sequenziali con librerie che implementano meccanismi di concorrenza
R ₃ : variabili condivise, risorse condivise, oggetti astratti usati per la cooperazione tra processi e thread
Interfaccia: istruzioni assembler
\mathbf{MV}_2 Macchina assembler \mathbf{L}_2 : assembler (D-RISC) \mathbf{R}_2 : registri, memoria, canali di comunicazione
Interfaccia: istruzioni firmware per l'assembler
\mathbf{MV}_1 Firmware \mathbf{L}_1 : microlinguaggio \mathbf{R}_1 : sommatore, commutatore, registri, strutture di interconnessione intra-unità e inter-unità
Interfaccia: hardware
\mathbf{MV}_0 Hardware \mathbf{L}_0 : funzionamento dei circuiti elettronici

R₀: circuiti elettronici elementari (AND, OR, NOT), collegamenti fisici, reti logiche

Il corso riguarderà principalmente i livelli $MV_2 \to MV_0$ inclusi, comprese le istruzioni assembler.

Il livello firmware sarà fatto da memoria, processore e dispositivi I/O. I dispositivi di I/O comunicano bilateralmente con la memoria e il processore comunica bilateralmente con memoria. Opzionalmente, i dispositivi di I/O comunicano bilateralmente direttamente con il processore. Questa è l'architettura standard, presentata in maniera estremamente semplicistica.

Vedremo nel dettaglio il processore e la memoria, non i dispositivi di I/O perché troppo complessi.

1.2.2 Struttura Interna

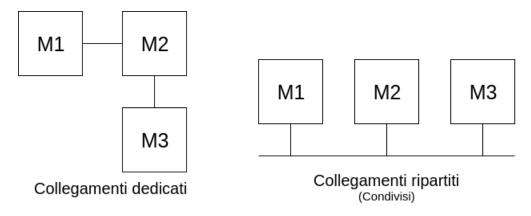
Da Verticale a Orizzontale Fin'ora abbiamo parlato delle macchine virtuali in senso verticale, adesso vogliamo trovare un modo concettualmente uniforme – orizzontale – per poter studaire i livelli al loro interno.

Sistema di Elaborazione Una volta scelta la struttura verticale di un sistema, dobbiamo capire come funziona l'interno di ciascun livello per poter far funzionare tutto il sistema, cioè dobbiamo capire come funziona il sistema di elaborazione di un livello composto da due componenti:

Moduli di Elaborazione, ad ognuno dei quali è affidata l'elaborazione di un sottoinsieme di operazioni del livello.

Struttura di Interconnessione, con la quale i moduli di elaborazione del livello cooperano e comunicano tra loro.

Essa può essere di due tipi:



Moduli di Elaborazione Un modulo di elaborazione è definito come un'entità autonoma e sequenziale.

Autonomia L'autonomia è data dal fatto che ogni modulo di elaborazione esegue un proprio controllo in maniera indipendente da altri moduli.

Esso dunque definisce le proprie strutture dati, operazioni elementari e interfacce verso altri moduli.

Sequenzialità La sequenzialità è data dal fatto che ogni modulo di elaborazione ha un singolo luogo di controllo: la sua attività è descritta da un algoritmo di controllo costituito da una lista sequenziale di comandi.

La sequenzialità non implica che un modulo non possa fare uso di forme di elaborazione concorrenti o parallele. Alcuni o tutti i comandi di una lista sequenziale possono essere costituiti da una o più operazioni elementari eseguite simultaneamente.

1.2.3 Parallelismo

Sovrapporre Poichè i moduli sono autonomi fra loro, sono in grado di operare indipendentemente l'uno dall'altro. Le loro attività possono quindi essere sovrapposte nel tempo eccetto quando, per ragioni legate alla sincronizzazione, alcuni di loro devono attendere il verificarsi di certi eventi dipendenti dall'elaborazione di altri. In alcuni casi limite seppur realistici, il funzionamento di tutti i moduli è rigidamente sequenziale.

Tutto questo vale per qualsiasi livello o Macchina Virtuale, quindi sia per firmware che hardware.

1.2.4 Modelli di Cooperazione

Dato un sistema di elaborazione a un certo livello, **i vari moduli** presenti **possono cooperare secondo due modalità**:

Ambiente Globale: esiste un insieme di oggetti comuni accessibili da tutti i moduli che devono cooperare tra loro, e tutti i moduli possono operare su tale insieme

Ambiente Locale: i moduli non condividono nulla, quindi non esiste alcun oggetto condivisio tra i moduli. La cooperazione avviene tramite scambio di messaggi.



1.3 Compilazione vs Interpretazione

Programmi L'obiettivo di un calcolatore è rendere possibile l'esecuzione di programmi con una certa qualità di servizio. I programmi vengono progettati mediante linguaggi di alto livello, quindi occorre operare una traduzione da linguaggio di alto livello a linguaggio assembler.

Tale traduzione può essere effettuata tramite due ben note tecniche e loro combinazioni:

Compilatore: è statico.

Sostituisce l'intera sequenza del programma sorgente con un sequenza di istruzioni assembler. Questa traduzione viene effettuata staticamente, vale a dire in fase di preparazione e prima che il programma passi in esecuzione.

Uno compilatore ha **completa visione del codice** e quindi **può ottimizzarlo**. La sua attività è analoga all'opera di un traduttore, che può leggersi il testo più volte per tradurlo alla perfezione.

Interprete: è dinamico

Scandisce la sequenza sostituendo ogni singolo comando con una sequenza na di istruzioni assembler. La traduzione è effettuata dinamicamente, cioè a tempo di esecuzione, quindi non può ottimizzare. Il firmware riceve un'istruzione alla volta, quindi la interpreta.

Il suo svantaggio è che il tempo di interpretazione viene pagato ogni volta che lancio il programma e che non può ottimizzare non avendo una visione globale del programma.

Entrambe servono per tradurre il **codice sorgente** nel **programma oggetto** o **eseguibile**. L'esecuzione è quindi **più veloce in un programma compilato** rispetto ad un programma interpretato.

ADD R1, R2, R3
$$\longrightarrow$$
 compilatore \longrightarrow OBJ \longrightarrow Interprete Firmware (interfaccia tra MV ASM e MV FW)

Intuitivamente, dall'istruzione ad alto livello viene **compilato un programma oggetto OBJ** il quale è un insieme di bit che **viene interpretato dall'interprete firmware**.

Esempio Suppongo programmi:

IF< \mathtt{R}_I , \mathtt{R}_N , LOOP

for i=0; i++; iA[i] = A[i] + B[i];
$$B[i] = B[i] + C$$
;

Ricevendo i due blocchi di istruzioni, il **compilatore riconosce che sono diverse e le compila in modo diverso.** Però in entrambi i casi sono del tipo *oggetto = somma due oggetti*, quindi produce una sequenza di istruzioni analoga (a meno di registri e dati, ovviamente). Parte del secondo pezzo di codice, ad esempio, verrà tradotto in questa maniera:

LOAD
$$R_{base}$$
, R_I , R_1 $M[R[base] + R[I]] \rightarrow R[1]$ ADD R_1 , R_2 , R_1 $R[1] + R[2] \rightarrow R[1]$ STORE R_{base} , R_I , R_1 $R[1] \rightarrow M[R[base] + R[I]]$ INC R_I $R[I] + 1 \rightarrow R[I]$

Microlinguaggio corrispondente

Capitolo 2

MV0 – Hardware

2.1 Reti Logiche

L'implementazione a livello hardware di funzioni "pure" dà luogo alle Reti Combinatorie. L'implementazione a livello hardware di funzioni "con stato" dà luogo alle Reti Sequenziali.

Famiglia Entrambe definiscono la famiglia delle Reti Logiche che permettono di realizzare il livello hardware di un sistema di elaborazione.

2.2 Reti Combinatorie

Una rete combinatoria è una rete logica con n ingressi binari $X_1 ... X_n$ e m uscite binarie $Z_1 ... Z_m$. Ad ogni combinazione di valori in entrata corrisponde una ed una sola combinazione di valori in uscita. La corrispondenza è definita secondo la funzione implementata dalla rete combinatoria.

Indichiamo $X_1 \dots X_n$ e $Z_1 \dots Z_m$ come variabili logiche di ingresso ed uscita. Tutte le combinazioni possibili delle variabili logiche sono dette stati di ingresso – con 2^n possibilità – e di uscita – 2^m possibilità.

Pe rdescrivere le proprietà e la struttura interna delle reti combinatorie si usa un'algebra isomorfa a quella logica, chiama Algebra Booleana.

2.2.1 Algebra Booleana

L'algebra booleana è computata su due valori e tre operatori:

false	AND
true	OR
	NOT

Esistono anche altri operatori, derivati dai tre precedenti: $\mathtt{XOR}, \mathtt{NAND}, \mathtt{NOR}$ ecc..

Proprietà Vale la proprietà distributiva anche per la somma rispetto alla moltiplicazione, oltre il viceversa, quindi: A(B+C) = AB + AC, ma anche A + BC = (A + B)(A + C). Inoltre si hanno le cosiddette **proprietà di DeMorgan**:

$$-\overline{A+B} = \overline{A} * \overline{B}$$
$$-\overline{AB} = \overline{A} + \overline{B}$$

AND						NOT	
Anche detta moltiplicazione logica.			Anche detta somma logica.			Anche detta negazione logica .	
X	Y	Z	X	Y		Y	\mathbf{Z}
0	0	0	0	0	0	0	1
0	1	0	0	1	1	1	0
1	0	0	1	0	1		
1	1	1	1	1	1		

Per costruire una rete combinatoria esistono varie tecniche. Quella che useremo si chiama somma di prodotti.

2.2.2 Tecnica della Somma di Prodotti, o codifica degli 1

La tecnica nel dettaglio Partendo dalla tabella di verità, identifico le uscite che valgono 1. Di quelle uscite, moltiplico (AND) tra loro le entrate sulla stessa riga, nego le entrate che valgono 0 e sommo (OR) tra loro le diverse righe.

Un esempio con la somma algebrica Partendo dalla seguente tabella di verità.

X Y \mathbf{Z} R 0 0 0 0 0 1 1 0 1 0 1 0 0 1 1

Sfruttando la tecnica descritta sopra ottengo le seguenti espressioni per le due uscite:

$$Z = \overline{X} * Y + X * \overline{Y}$$

$$R = X * Y$$

Alternativamente, posso anche realizzare la **funzione complementare**, ovver fare il solito procedimento ma per le uscite che valgono 0 per poi negarle.

$$Z = \overline{\overline{X} * \overline{Y} + X * Y}$$

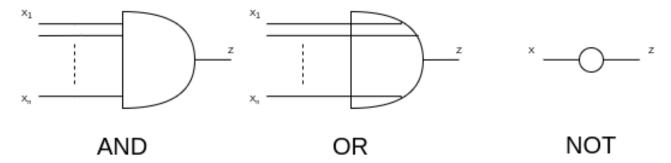
$$R = X * Y$$

Esempio

 $\mathrm{S1}^* = \overline{S1}^* \overline{S2}^* \mathrm{X}^* \mathrm{Y} + \overline{S1}^* \mathrm{S2}^* \mathrm{X}^* \mathrm{Y} + \mathrm{S1}^* \overline{S2}^* \overline{X}^* \overline{Y} + \mathrm{S1}^* \overline{S2}^* \mathrm{X}^* \overline{Y} + \mathrm{S1}^* \overline{S2}^* \mathrm{X}^* \mathrm{Y} + \mathrm{S1}^* \mathrm{S2}^* \overline{X}^* \mathrm{Y} + \mathrm{S1}^* \mathrm{S2}^* \mathrm{X}^* \mathrm$

2.2.3 Porte Logiche

Una volta ricavata l'espressione logica dalla tabella di verità, è immediato realizzare lo schema logico utilizzando le componenti hardware elementari, dette anche porte logiche:

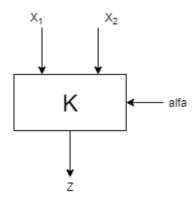


Ogni porta logica AND e OR comporta un ritardo nel calcolo di 1 T_p . Inoltre, ogni AND e OR può avere massimo 8 ingressi, quindi se ho più di 8 segnali in ingresso devo avere *almeno* due livelli: un livello con tante porte logiche quando n/8 con n numero di segnali in ingresso, e *almeno* un livello in cui "unire" i segnali in uscita in una porta logica analoga.

2.2.4 Componenti Standard

Di seguito sono le specifiche di alcune **reti combinatorie** che verranno supposte come **standard**, ovvero come componenti utilizzabili come blocchi elementari nella progettazione di strutture più complesse.

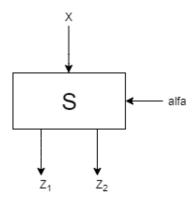
Commutatore

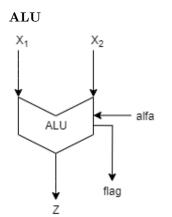


Selezionatore



Confrontatore





2.2.5 Ritardo di Stabilizzazione

Prestazioni Per valutare le prestazioni di un sistema, occorre saper valutare le prestazioni delle reti combinatorie. Ogni rete reale è caratterizzata da un ritardo T_r , necessario affinché a seguito di una variazione dello stato d'ingresso si produca la corrispondente variazione dello stato in uscita. Solo dopo questo tempo si dice che la rete è stabilizzata.

 \mathbf{T}_p Per una porta logica indichiamo con \mathbf{T}_p il ritardo di stabilizzazione – ad oggi è di circa 10^{-2} millisecondi. Supponiamo che le **porte NOT** abbiano un ritardo nullo, pari a 0 \mathbf{T}_p , mentre per le **porte AND/OR** il valore \mathbf{T}_p dipende dal numero di ingressi n della porta. Per $\mathbf{n} \leq 8$ supponiamo che le porte AND/OR abbiano un ritardo di stabilizzazione di $\mathbf{1}$ \mathbf{T}_p .

Il costo in T_p sarà quindi pari ai livelli di AND/OR presenti. Ad esempio, se ho una tabella di verità con n termini ed m variabili, avrò $\log_8 n$ livelli di OR e $\log_8 m$ livelli di AND. Il costo in T_p sarà quindi = $(\log_8 n + \log_8 m)$ T_p

2.2.6 Registri e memorie

2.3 Reti Sequenziali

Una rete sequenziale è un oggetto con un ingresso ed una uscita, capace di mantenere uno stato interno – ecco perché si parla di funzioni con stato. A livello hardware, possiamo identificare una rete sequenziale con un automa a stati finiti.

ASF Un automa a stati finiti è caratterizzato da:

n variabili di ingresso \Rightarrow h = 2^n stati di ingresso $X_1...X_h$

m variabili di uscita \Rightarrow k = 2^m stati di uscita $Z_1...Z_k$

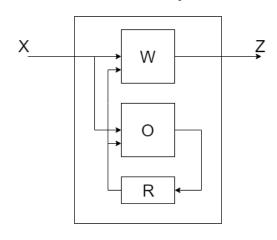
r variabili logiche dello stato interno \Rightarrow p = 2^r stati interni $S_1 \dots S_p$

una funzione di transizione dello stato interno σ : X x S \to S che definisce il passaggio tra gli stati

una funzione delle uscite $\omega \colon X \times S \to Z$ che calcola le uscite

Una rete sequenziale è quindi composta da due reti combinatorie σ e ω , che rispettivamente calcolano la variazione dello stato e l'uscita, e da un registro $\mathbf R$ che contiene lo stato interno.

2.3.1 Modello di Mealy



Considerando il comportamento al tempo t, lo **stato interno successivo S(t+1)** dipende sia dallo stato di ingresso al tempo t, cioè X(t), sia dallo stato interno attuale S(t).

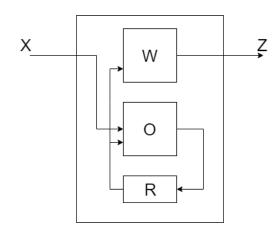
$$S(t+1) = \sigma(X(t), S(t))$$

Lo stato di uscita al tempo t, Z(t), dipende sia dallo stato di ingresso X(t) sia dallo stato interno attuale S(t).

$$Z(t) = \omega(X(t), S(t))$$



2.3.2 Modello di Moore

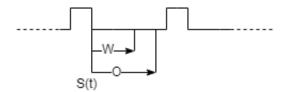


In maniera analoga al modello di Mealy, lo **stato interno successivo S(t+1)** dipende sia dallo stato di ingresso al tempo t, cioè X(t), sia dallo stato interno attuale S(t).

$$S(t+1) = \sigma(X(t), S(t))$$

Lo stato di uscita al tempo t, Z(t), dipende solo dallo stato interno attuale S(t).

$$Z(t) = \omega(S(t))$$



2.3.3 Reti Sequenziali di tipo Sincrono

Vediamo adesso come si comportano nel tempo le reti sequenziali e spieghiamo perché adotteremo quelle di tipo sincrono. Come riferimento usiamo una rete di Mealy.

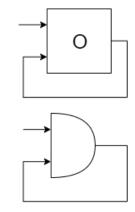
Spezzare Abbiamo detto che lo stato al tempo successivo S(t+1) dipende sia dall'ingresso X sia dallo stato interno attuale S(t), cioè $S(t+1) = \sigma(X(t), S(t))$.

Il registro R funge come un "cancello temporizzato" che spezza la sequenza temporale degli eventi.

Se il registro R non fosse presente, si verificherebbe la situazione in figura. In questo esempio, la porta logica o il componente σ **potrebbero non stabilizzarsi mai**. Se per esempio mettiamo una porta AND con due variabili in ingresso che nega il proprio risultato, tale rete tenderà a non stabilizzarsi mai ma a produrre una sequenza infinita di 0 e 1 in uscita.

Quindi devo avere necessariamente un meccanismo che mi possa aiutare a determinare il valore dell'uscita al tempo $t,\,t+1\ldots$

Questo strumento è il resgistro impulsato, dove la scrittura è scandita dal ciclo di clock.

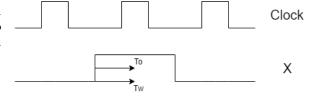


Modo Sincrono Questo modo di lavorare delle reti sequenziali con un registro impulsato che funge da cancello temporizzato grazie al ciclo di clock si chiama Modo Sincrono.

Quando variare Cerchiamo ora di capire quando devono variare gli ingressi e **per quanto tempo devono avere** tale valore.

Supponiamo di avere gli ingressi $X_0=0$ al tempo $t,\,X_1=1$ al tempo t+1 e $X_2=0$ al tempo t+2, e supponiamo che $t_\omega=t_\sigma=2t$.

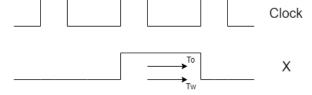
Se l'ingresso X variasse in un punto non precisato del ciclo di clock è probabile che ω e σ non abbiano il **tempo** necessario per produrre un risultato e quindi avrei un comportamento indefinito.



In questo caso, cambiando il valore X all'inizio del ciclo di clock do il tempo necessario a σ e ω di produrre un risultato stabile, ma al prossimo impulso del ciclo di clock (t + 2) leggerò di nuovo X = 1, che non è l'input corretto al tempo t + 2.



Questa è la soluzione giusta per il nostro esempio, che rispetta tutte le condizioni da noi elencate.



Per far funzionare le nostre reti, il ciclo di clock deve essere tale che $T = MAX(t_{\sigma}, t_{\omega}) + \delta$. Le reti funzionano anche con $T > MAX(t_{\sigma}, t_{\omega}) + \delta$, ma avrei del **tempo perso** poiché la rete non opera, **aspetta solo che il clock sia alto per andare a scrivere nel registro**.

2.3.4 Reti Sequenziali a Componenti Standard

Per poter sintetizzare una rete devo prima decidere se implementare un modello di Mealy o di Moore, derivare le tabelle di verità di ω e σ e dire quanti bit ha il registro R.

Fatto questo, ricavare le reti combinatorie e capire quanto valga il ciclo di clock T (con $T = MAX(t_{\sigma}, t_{\omega}) + \delta$) che fa funzionare l'intera rete sequenziale.

Sintesi Classica ASF \longrightarrow Mealy o Moore \rightarrow Tabelle verità, bit di R \Rightarrow Reti combinatorie \Rightarrow Ciclo di clock

Componenti Standard In realtà per sintetizzare le reti sequenziali non usiamo questo procedimento di sintesi, ma bensì usiamo i componenti standard. Per esempio, prendiamo una rete che vuole calcolare il numero di persone presenti dentro una stanza con capienza massima 100 persone.

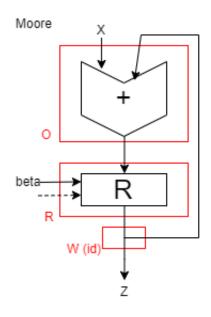
Con la sintesi classica R ha bisogno di 7 bit per contare da 0 a 100.

Se andiamo, per esempio, a fare la tabella di verità per ω , abbiamo ben 8 colonne negli ingressi, quindi 2^8 possibili combinazioni (righe).

Potrei avere $2^{8}/2 = 2^{7}$ "uni" per colonna, di conseguenza un numero considerevole di porte logiche.

Diventa quindi praticamente impossibile sintetizzare questo esempio con il metodo classico. Procediamo con l'alternativa: l'utilizzo delle componenti standard.

Con le componenti standard Procediamo col nostro esempio:

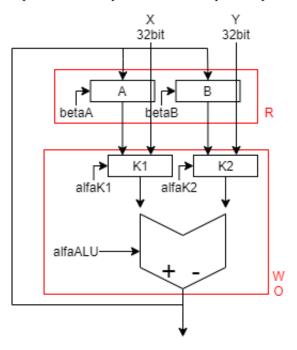


In questo caso abbiamo usato il modello di Moore. Il risultato è disponibile al prossimo impulso del ciclo di clock.



Qua invece è stato usato il modello di Mealy. In questo caso si vede bene come la rete di Mealy sia più veloce, poiché il risultato è subito disponibile prima del prossimo impulso del ciclo di clock: infatti Z non viene scritto in R prima di essere pubblicato.

Di seguito un esempio di rete sequenziale a componenti standard più complesso.



Con sintesi classica Avrei:

 $R = \{A, B\},$ due registri da 32 bit $\Rightarrow 64$ bit

Ingressi: X + Y +
$$\alpha_{K1}$$
 + α_{K2} + α_{ALU} + β_{A} + β_{B} = 32 + 32 + 3 + 2 = 69

Uscite: $Z \Rightarrow 32$ bit

La tabella di verità di ω , per esempio, avrebbe 69 colonne di ingressi, quindi 2^{69} righe, **senza considerare gli ingressi** di \mathbf{A} e \mathbf{B} .

Il risultato è che è molto scomodo lavorare con una tabella di circa 5.9 * 10^{20} righe.

Capitolo 3

MV1 - Firmware

3.1 Unità Firmware

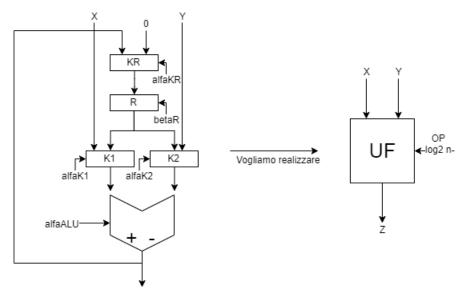
Un sistema di elaborazione, a livello Firmware, è costituito da un certo numero di **Unità Firmware** che interagiscono fra loro mediante un sistema di interconnessione. Le UF sono capaci si svolgere un certo numero di operazioni esterne.

Unità Firmware Una unità firmware è un modulo di elaborazione autonomo – cioè capace di controllare la propria operazione in modo del tutto indipendente – e sequenziale – cioè dal funzionamento descritto da un programma sequenziale – capace di eseguire delle operazioni esterne – istruzioni assembler.

Struttura di interconnessione Tipicamente la struttura di interconnessione tra unità firmware è punto-a-punto quindi a collegamenti dedicati.

3.1.1 PC e PO

Per capire bene cosa sono e a cosa servono le parti controllo (PC) e operativa (PO), vediamo un semplice esempio di come arriviamo a strutturare un'unità firmware.



Il nostro obiettivo è quello di realizzare una unità capace di produrre un risultato Z a partire dalle variabili in input, fornendogli solo le istruzioni per l'operazione da implementare e capace di gestire tutte le variabili di controllo (α, β) in maniera autonoma.

L'unità firmware è quindi l'unione di due oggetti:

Parte Controllo che "comanda" l'operazione da eseguire

Parte Operativa che "esegue" l'operazione

Ciclo di Clock



PO e PC sonoreti sequenziali impulsate dallo stesso segnale di clock, quindi aventi lo stesso ciclo di clock. Il ciclo di clock dell'unità firmware viene determinato in modo da permettere la stabilizzazione di entrambe le reti per l'esecuzione di una qualsiasi microisitruzione.

Questo modello di programmazione è sincrono.

Schematizzazione del diagramma del ciclo di clock sopra:

 ω_{PO} : prepara i valori che servono alla PC per decidere cosa fare

 ω_{PC} : prepara $\{\alpha, \beta\}$ che implementano l'operazione richiesta

 σ_{PC} : decido il prossimo stato interno della PC \rightarrow scrivo il registro R della PC

 σ_{PO} : eseguo l'operazione pianificata \rightarrow scrivo i nuovi valori nei registri che compongono lo stato interno della PO

Parte Operativa, Moore

Rete Sequenziale progettata con componenti standard che provvede all'esecuzione di istruzioni tramite commutatori, selettori, ALU e registri.

Parte Controllo, Mealy

Rete Sequenziale progettata tramite sintesi classica che provvede a determinare le variabili di controllo α e β per la parte operativa.

Mealy o Moore?

Essendo entrambe due reti sequenziali bisogna decidere quale modello usare. Analizziamo le varie combinazioni di modelli.

Mealy–Mealy Se uso un modello Mealy–Mealy le uscite di ω_{PO} vanno direttamente nella ω_{PC} e le uscite di ω_{PC} ritornano in ω_{PO} . Non ho un registro che ferma il ciclo continuo tra ω_{PC} e ω_{PO} , quindi non riuscirò mai a stabilizzare i segnali che si scambiano PO e PC.

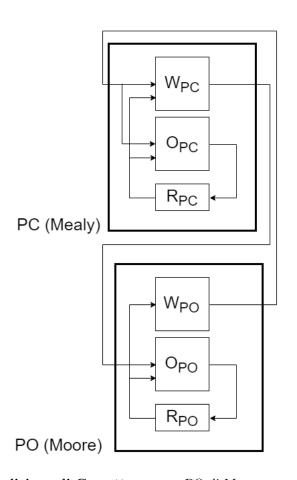
Viene naturale pensare di farle entrambe Mealy–Mealy poiché, come visto in precedenza, il modello di Mealy è più veloce di quello di Moore.

Almeno una Moore Concludiamo che almeno una tra PC e PO deve essere di Moore per poter stabilizzare l'intera UF, ma quale?

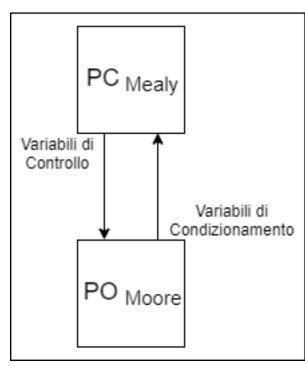
La risposta corretta è usare il modello di Mealy per la Parte Controllo e il modello di Moore per la Parte Operativa in modo da avere dei comandi veloci ed una esecuzione più lenta rispetto alla PC.

Il contrario? Non scegliamo un modello Moore per PC e Mealy per PO perché è illogico avere un esecutore veloce che deve aspettare un controllore lento: inutile avere una macchina molto veloce se inserisco i comandi molto lentamente.

Anche un modello Moore–Moore non è comodo da usare, seppure funzionante correttamente, perché avrei entrambe le parti lente.



Unità Firmware



Condizione di Correttezza \Rightarrow PO di Moore

Le uscite della Parte Operativa, cioè le variabili di condizionamento, dipendono esclusivamente dallo stato interno di PO, cioè tutte le variabili di condizionamento devono essere prodotte senza usare alcun α

3.1.2 Procedimento Formale

Schematizzazione dei passaggi del procedimento formale per la costruzione e l'analisi di una rete sequenziale.

- 1. Descrizione a parole delle operazioni esterne
- 2. Programma scritto in μ -linguaggio
- 3. Componenti

 R_{PO} : capire quali sono i registri di stato della PO

 $\omega_{PO},\,\sigma_{PO}$: capire le funzioni che mi servono nella PO

 \mathbf{R}_{PC} : capire cosa è lo stato della PC

 $\omega_{PC},\,\sigma_{PC}$: capire cosa calcolare nella PC

 \longrightarrow T = t(ω_{PO}) + MAX{t(ω_{PC}) + t(σ_{PO}), t(ω_{PC})} + δ

Capitolo 4

μ -linguaggio

Si formalizza un linguaggio chiamato μ -linguaggio che permetta di derivare formalmente com'è fatta la PC e la PO di una certa UF.

4.1 Istruzioni

Nel μ -linguaggio sono presenti solamente due tipi di istruzione:

```
n. \mu op_1, ..., \mu op_k, m
```

Le op sono operazioni di trasferimento tra registri. Le varie op separate da una virgola sono eseguite contemporaneamente – cioè nello stesso ciclo di clock.

m finale indica a quale istruzione andare dopo aver eseguito questa istruzione, la n.

```
n. (condizione = T) \mu op_1, ..., \mu op_k, m' (condizione = F) \mu op_1, ..., \mu op_h, m''
```

Le condizioni sono date in termini di variabili di condizionamento. Possono essere messe in sequenza, venendo valutate in sequenza.

Posso considerare solo variabili booleane o espressioni di cui mi interessa solo il risultato senza memorizzarlo.

Esempio Vediamo un esempio di come scrivere un programma in μ -linguaggio. Prendiamo come esempio la divisione fra interi.

Linguaggio pseudo-C

 μ -linguaggio

Ogni μ -istruzione è **eseguita esattamente in un ciclo di clock**. Nell'esempio, per eseguire il programma avrò bisogno di almeno 5 cicli di clock, a meno di iterazioni interne.

4.2 Ottimizzazione del codice

Dopo aver scritto il μ -codice possiamo provare ad **ottimizzarlo**, cioè **ridurre il numero di cicli di clock necessari** ad eseguirlo.

Un'ottimizzazione possibile dell'esempio precedente è la seguente.

Considero un registro T dove memorizzo il risultato di A - B. Di quel registro T, considero T_0 - cioè il bit più significativo - per il segno.

Inoltre elimino le nop, che sono tempo sprecato.

4.2.1 Condizioni di Bernstein

Per eseguire le ottimizzazioni sul μ -codice, dobbiamo **seguire le Condizioni di Bernstein**. Tali condizioni forniscono delle regole per verificare se due o più μ -operazioni possono essere eseguite nella medesima μ -istruzione.

Le Condizioni Per capire se

i. μop_A , i+1

i+1. μ op $_B$, k

è equivalente a

i. μop_A , μop_B , k

Bisogna valutare il dominio R(op) – registri letti da op – e il codominio W(op) – registri scritti da op – delle μ -operazioni.

Nell'esempio precedente:

$$R(A - B \rightarrow T) = \{A, B\}$$

$$W(A - B \to T) = \{T\}$$

$$R(Q + 1 \rightarrow Q) = \{Q\}$$

$$W(Q + 1 \rightarrow Q) = \{Q\}$$

Le condizioni da verificare sono:

$$W(\mu op_A) \cap R(\mu op_B) = \emptyset$$

Dipendenza: non posso mettere insieme μ -operazioni tali che la prima scrive in un registro letto dalla seconda.

$$W(\mu op_A) \cap W(\mu op_B) = \emptyset$$

Dipendenza di output: non posso scrivere nello stesso registro con due μ -operazioni diverse nella stessa μ -istruzione.

4.2.2 Variabili di Condizionamento

Le variabili di condizionamento possono essere così categorizzate:

Semplici: indicano le uscite di registri senza trasformazioni

$$\longrightarrow t_{\omega PO} = 0$$

Complesse: indicano trasformazioni delle uscite di registri fatte tramite reti combinatorie prive di ingressi di controllo.

$$\longrightarrow t_{\omega PO} = k t_p$$

4.2.3 Tempo medio di elaborazione

Il tempo medio di elaborazione di una UF viene valutato come: $T = \sum_{i=0}^{n-1} (p_i * k_i)$ Dove:

 k_i è il numero medio di cicli di clock necessari per eseguire una generica operazione i

 p_i è la probabilità di eseguire tale operazione

Quando non sono note le p_i , si assume che tutte le sottosequenze siano equiprobabili. Calcoliamo quindi T come media aritmetica dei k_i , oppure si cerca di stimare se possibile una distribuzione probabilistica attendibile.

4.2.4 Riflessioni finali sull'ottimizzazione

Bisogna prestare particolare attenzione quando si ottimizza il μ -codice. Ridurre il numero di μ -istruzioni (k_i) non è sempre qualcosa di buono.

Talvolta, unire due o più μ -istruzioni obbliga ad aumentare il ciclo di clock T per consentire al μ -programma di eseguirle tutte. Questa modifica, che si applica a tutte le μ -istruzioni, potrebbe aumentare il tempo medio di elaborazione T, rendendo il programma complessivamente più lento.

Concludendo, le ottimizzazioni che si possono fare sono:

Eliminare le nop, tranne quelle di attesa per operazioni esterne

Raggruppare le μ -operazioni, attraverso le condizioni di Bernstein

Raggruppare le condizioni logiche

4.3 Controllo Residuo

Per diminuire ulteriormente la complessità della PC possiamo delegare alla PO alcune delle decisioni che dovrebbe prendere la PC.

Vediamo alcuni esempi:

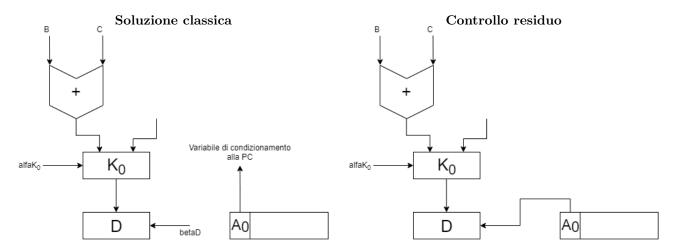
Leggere il k-esimo bit di un registro R di n bit





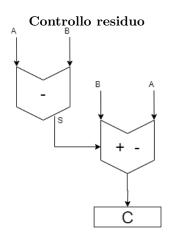
Risparmio complessità della PC e riduco il traffico di dati da PO a PC

Supponiamo una μ -istruzione da eseguire a seconda di una certa condizione, ad esempio: (A $_0$ = 0) B + C \rightarrow D



(segno(A - B) = 0) B - A
$$\rightarrow$$
 C (= 1) B + A \rightarrow C





4.4 Comunicazioni

Con comunicazioni si intendono le comunicazioni fra unità firmware e mondo esterno e viceversa. Nell'esempio preso in esame, della divisione fra A e B interi con Q ed R risultati, A e B provengono dal mondo esterno e Q ed R sono comunicati verso di esso.

$$A,B \longrightarrow UF \longrightarrow Q,R$$

Categorie Le comunicazioni sono classificate in due categorie:

Simmetriche/Asimmetriche

Simmetriche: un solo mittente, un solo destinatario (uno-a-uno)

Asimmetriche: asimmetria in ingresso (più mittenti) o in uscita (più destinatari)

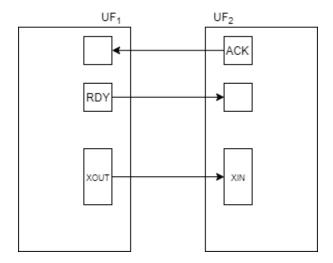
Sincrone/Asincrone

Sincrone: la comunicazione avviene "istantaneamente"

Asincrone: il destinatario legge il messaggio dopo del tempo (es. e-mail)

4.4.1 Protocollo a Livelli

Simmetrico e asincrono, il protocollo a livelli funziona aggiungendo ai registri XOUT di UF_1 e XIN di UF_2 altri due registri da 1 bit ciascuno, che indicano quando avviene la comunicazione: ACK e RDY



Di seguito i passi del funzionamento del protocollo:

1. UF $_{\!1}$ scrive XOUT e il primo registro da 1 bit

Situazione iniziale
$$0 \qquad 0$$
 $1 \longrightarrow 0$

Situazione finale
$$0 \qquad 0$$
 $1 \longrightarrow 1$

1 in RDY di UF_2 significa
 che ci sono dati significativi in XIN

2. UF $_2$ utilizza XIN e comunica che ha finito scrivendo nel proprio registro di OUT da 1 bit

Situazione iniziale
$$0 \leftarrow 1$$
 $1 \rightarrow 0$

Situazione finale
$$1 \leftarrow 1$$
 $1 \rightarrow 1$

3/4. Ritorno alla situazione iniziale con tutti i registri da un bit a 0

$$\begin{array}{ccc} 1 & \longleftarrow & 1 \\ 0 & \longrightarrow & 1 \end{array}$$

$$\begin{array}{ccc} 1 & \longleftarrow & 1 \\ 0 & \longrightarrow & 0 \end{array}$$

$$\begin{array}{cccc} 1 & \longleftarrow & 0 \\ 0 & \longrightarrow & 0 \end{array}$$

$$\begin{array}{ccc} 0 & \longleftarrow & 0 \\ 0 & \longrightarrow & 0 \\ \text{Si può riniziare} \end{array}$$

Vediamo i cicli di clock necessari per usare questo protocollo:

- 1. UF₁ scrive 1
- 2. UF₂ vede $1 \to \dots$ UF₂ agisce... \to UF₂ scrive 1
- 3. UF₁ vede 1 di ritorno \rightarrow UF₁ scrive 0
- 4. UF₂ vede $0 \rightarrow$ UF₂ scrive 0
 - ⇒ Condizioni iniziali: 4 cicli di clock

Se le due UF hanno clock sfasati uso lo stesso ragionamento, probabilmente finendo per dover usare più cicli di clock.

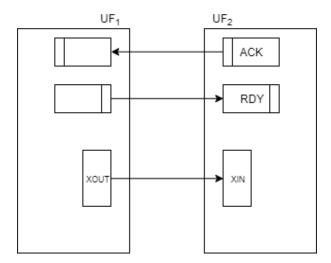
24

Nel programma Come rendere questo meccanismo nel μ -codice? Proviamo a scriverlo per UF₂:

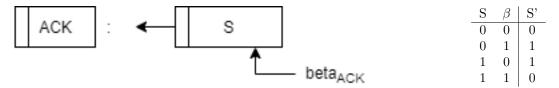
Questo protocollo è particolarmente semplice e necessita **pochissimo hardware**, ma **richiede troppi cicli di clock per comunicare**. Vediamo un'alternativa migliore.

4.4.2 Protocollo a Transizione di Livello

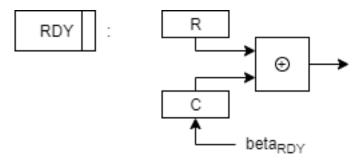
Simmetrico e asincrono, simile al protocollo a livelli ma usa degli indicatori di transizione di livello.



ACK Contatore in modulo 2, quindi cambia stato $(0 \leftrightarrow 1)$ ogni volta che ci scrivo.



RDY Risultato di un confrontatore fra un contatore modulo 2 e un registro in ingresso.



Funzionamento Dal punto di vista di UF₂.

Quando arriva un segnale da UF₁, la rete RDY diventa 1, quindi si può lavorare con i dati ricevuti.

Per comunicare a UF₁ che l'operazione è conclusa, mando un $\beta_{ACK}=1$ al mio ACK, che diventerà 1 anche in uscita.

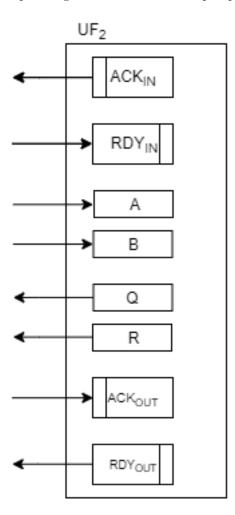
Questo procedimento è il medesimo del protocollo a livelli visto in precedenza. Quello che cambia è come mi riporto nelle condizioni iniziali.

Dopo aver lavorato con XIN, chiamo reset RDY che riporta la rete RDY a 0, quindi pronta ad accogliere un nuovo messaggio.

In poche parole, torno alle impostazioni iniziali nello stesso momento in cui ricevo il messaggio.

Esempio

Per capire meglio vediamo come esempio quello in esame, la divisione fra A e B interi con risultati Q, R.



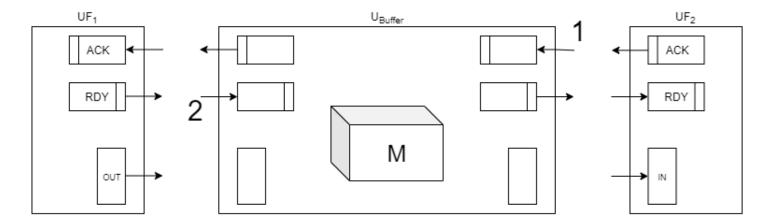
Possiamo notare che UF₁ manda i segnali A e B e non ha altre operazioni mentre attende la risposta Q, R da UF₂. Questa situazione si chiama protocollo domanda/risposta e solo in questo caso basta una coppia di indicatori di transizione.

```
UF1
0. ... -> A, set RDY, 1
1. (ACK = 0) nop, 1
    (= 1) B -> ..., reset ACK

UF2
0. (RDY = 0) nop, 0
    (= 1) A -> ..., 1
... elaborazione di UF2 ...
n. ... -> B, set ACK, reset RDY, 0
```

4.4.3 Comunicazioni asincrone a n posizioni

In questo caso non esiste una soluzione basata su semplici interfacce nelle due unità comunicati, ma è necessario introdurre una terza unità (chiamata unità buffer) che implementi una coda FIFO a n posizioni. Il mittente può spedire al più n messaggi senza che il destinatario effettui ricezioni.



- 1 Se ci sono messaggi in memoria M, manda un messaggio a UF₂
- 2 Se c'è posto in memoria M, riceve un messaggio da UF₁ e lo memorizza in M

Se valgono entrambe ed M è vuota, allora il messaggio in ingresso da UF₁ viene passato direttamente ad UF₂

 U_{buffer} Il codice di U_{buffer} avrà come variabili di condizionamento RDY da UF_1 , ACK da UF_2 , condizione di memoria piena e condizione di memoria vuota.

Le due condizioni di memoria piena/vuota possono essere gestite tramite un semplice contatore. SE per esempio abbiamo una memoria M con 2^k posizioni, useremo un contatore da k + 1 bit:

Memoria vuota OR(CONT) = 0

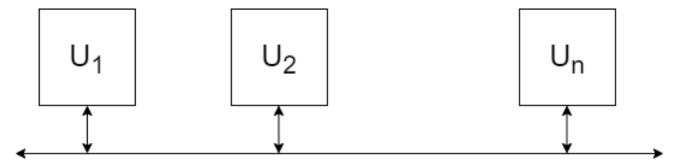
Memoria piena $CONT_0 = 1$

 \Rightarrow 0. (RDY, ACK, OR(CONT), CONT₀, ...

Il buffer implementa una politica FIFO: il primo messaggio inviato da UF_1 deve essere il primo messaggio letto da UF_2

4.4.4 Comunicazioni asimmetriche

BUS Per poter parlare delle comunicazioni asimmetriche è necessario introdurre il concetto di BUS. Un BUS è un insieme di linee per trasportare dati (es. da 32 bit), l'indirizzo (es. log₂ n bit) e una linea da 1 bit che indica l'operazione da svolgere.



Il grosso svantaggio di questo tipo di comunicazione è che le unità possono comunicare solamente una alla volta. Ho bisogno quindi di un meccanismo di arbitraggio che regola l'ordine di comunicazione delle varie unità. Vedremo due tipi di arbitraggio: centralizzato e distribuito.

Inoltre avremo a disposizione anche un protocollo d'interazione Unità — BUS:

richiesta da U_i di uso del BUS \rightarrow comunicazione (uso del BUS) \rightarrow rilascio della risorsa.

Rimane da sottolineare il **problema della sincronizzazione**. Abbiamo bisogno di indicatori a livello per poter comunicare in maniera asimmetrica con un BUS.

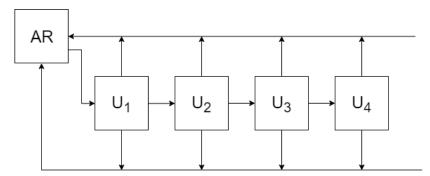
Arbitri Centralizzati

Arbitro Centralizzato a Richieste Indipendenti La unità hanno un collegamento diretto con l'arbitro



L'arbitro AR considera le richieste, fra di esse individura l'unità U_i vincitrice secondo una certa politica P e assegna la richiesta all'unità individuata. Dopodiché, attende il rilascio della risorsa assegnata.

Arbitro Centralizzato Daisy Chaining Abbiamo un numero minore di ingressi ma la stessa politica del caso precedente.



Il vantaggio di questo arbitro è la sua semplicità: due ingressi ed una uscita.

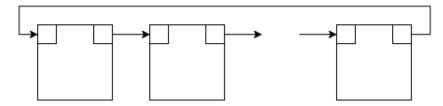
L'arbitro, se c'è richiesta, manda il segnale di disponibilità alla prima unità. Il segnale viene passato da unità ad unità, finché non viene trovata l'unità che ne ha fatto richiesta. A tal punto, tale unità manda all'arbitro il bit di occupato, ed inizia ad utilizzare la risorsa. Infine, l'arbitro attende che il bit di occupato torni a 0.

Arbitro Centralizzato Polling L'arbitro interroga le varie unità per sapere se hanno bisogno della risorsa BUS, ed assegna le risorse secondo una certa politica.

Aribtro Centralizzato a Divisione di Tempo Questa soluzione consiste nell'assegnare l'accesso alla risorsa comune ad ogni unità U_i per istanti di tempo ben determinati.

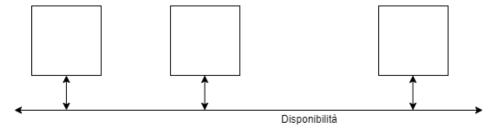
Arbitri Decentralizzati

Arbitro Decentralizzato a Disciplina Circolare (Token Ring)



Se U_i riceve 1 (token) in ingresso e deve utilizzare la risorsa allora la usa. In ogni caso, sia che debba utilizzarla sia che non debba farlo, passa il token in uscita alla prossima unità.

Non Deterministici Usati soprattutto nelle reti wireless.



In questa tipologia di arbitro può succedere che due o più unità rilevino la disponibilità e inizino a trasmettere contemporaneamente.

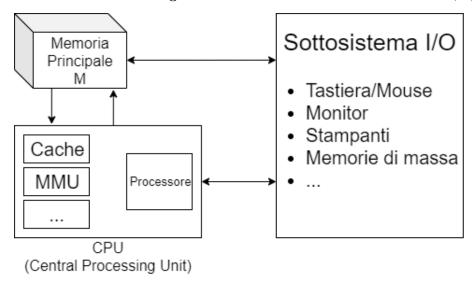
Tale problema viene risolto con **un sistema per rilevare le collisioni**: ogni unità che trasmette ascolta ciò che l'arbitro trasmette. Se ciò che ascolta è il medesimo segnale che ha inviato allora l'invio del messaggio è andato a buon fine, altrimenti se ascolta un messaggio differente allora aspetta un lasso di tempo casuale per poi ritentare la trasmissione.

4.5 Memoria Modulare

Capitolo 5

Macchina Assembler

In questa parte andremo a vedere alcuni moduli che sono unità firmware a tutti gli effetti, con una certa struttura di interconnessione e che riescono ad eseguire istruzioni assembler ASM. In sostanza, i processori.



5.1 CPU

 $\begin{array}{ll} \textbf{Processore} & \textbf{Una unit\`a firmware in grado di eseguire operazioni esterne che sono istruzioni del linguaggio \\ \textbf{ASM}. \end{array}$

Cache Una memoria piccola ma molto veloce, che contiene il sottoinsieme della memoria principale M che permette di eseguire un certo programma.

MMU La Memory Management Unit è il componente che permette di tradurre gli indirizzi logici generati dal processore in indirizzi fisici

Logicamente Dal punto di vista logico, un processore P fa un ciclo infinito in cui legge l'istruzione all'indirizzo IC (Instruction Counter) o PC (Program Counter), la decodifica e la esegue, poi aggiorna IC e gestisce le interruzioni (eventi generati dal sottosistema I/O)

5.2 Istruzioni ASM

Dati Le istruzioni assembler (ASM) operano sostanzialmente su due tipi di dato:

Registri Generali RG: pochi, velocissimi, lunghi una parola, a doppia porta (permettono di leggere due locazioni e scrivere una locazione nello stesso ciclo di clock)

Locazioni di memoria: molte, lente, lunghe una parola, esterne al processore che interagisce con M tramite un meccanismo domanda/risposta.

Istruzioni I tipi di istruzioni presenti sono:

 $\mathbf{Operative} \colon \mathrm{somma}, \, \mathrm{shift} \dots \\$

Accesso alla memoria: lettura $(M \to RG)$ o scrittura $(RG \to M)$

Salto Condizionale, con condizione sui RG

Salto Incondizionale

5.3 Programmi e processi

Assumeremo che ogni programma ASM veda uno Spazio di Indirizzamento detto Memoria Virtuale (MV), schematizzato di seguito.

MV La memoria virtuale la vediamo come un vettore le cui posizioni vanno da un indirizzo 0 ad un indirizzo MAX (indirizzi logici), ognuno dei quali corrisponde ad una parola (32/64 bit). Lo spazio viene organizzato secondo lo schema a fianco.

